

ISTRUZIONI R

Sommario

Tuber	2
Retriving dei commenti:	2
Analizzare i testi	3
Individuazione delle multiwords	3
Analisi	5
Mostwords	5
Contesto delle parole (1)	5
Udpipe completo	6
Analisi delle occorrenze	7
Statistiche di frequenza	7
Sostantivi	7
Aggettivi	8
Co-occorrenze di nomi e aggettivi nella stessa frase	9
Co-occorrenze di nomi e aggettivi che si susseguono	10
Correlazioni	11
Contesto delle parole (2)	11

Tuber

Retriving dei commenti:

Dopo l'installazione, il caricamento dei pacchetti “**tuber**”, “**writexl**” e “**dplyr**” e l'autenticazione con **client_id** e **client_secret**, ho ottenuto le statistiche del canale “[Breaking Italy](#)” (solo dopo aver ricavato l'id del canale) creando l'oggetto “**stat_canale**” e selezionando id, titolo, descrizione, paese, numeri delle visualizzazioni, delle iscrizioni e dei video:

```
stat_canale<-as.data.frame(get_channel_stats("UC4V3oCikXeSqYQr0hBMARwg"))
stat_canale<-select(stat_canale,
                    "id",
                    "snippet.title",
                    "snippet.description",
                    "snippet.country",
                    "statistics.viewCount",
                    "statistics.subscriberCount",
                    "statistics.videoCount")
```

```
Channel Title: Breaking Italy
No. of Views: 295531679
No. of Subscribers: 870000
No. of Videos: 2805
```

Ho allora creato gli oggetti “**ricerca**” digitando i termini utili a trovare i video che mi interessavano, ed “**E**” scegliendo i video dall'elenco che si era creato:

```
# RICERCARE VIDEO
ricerca<-tuber::yt_search(term="giornalista podcast teatro",
                          channel_id="UC4V3oCikXeSqYQr0hBMARwg")

E<-ricerca[c(2, 3, 8, 14), ]
```

	video_id	publishedAt	channelId	title	description
2	gRvIHb6HUOY	2022-12-17T14:00:08Z	UC4V3oCikXeSqYQr0hBMARwg	Come si arriva a raccontare i teatri di guerra? Cecilia Sala parla della sua esperienza	
3	5_B9PfpMplQ	2021-11-06T14:00:12Z	UC4V3oCikXeSqYQr0hBMARwg	Francesco Costa - Breaking Italy Podcast	
8	TYZ3JOm6rKw	2024-05-04T13:00:08Z	UC4V3oCikXeSqYQr0hBMARwg	Giovanni Floris: l'etica, le interviste, il mirto bianco	
14	Eu7sxxg-hD6A	2022-01-08T14:00:11Z	UC4V3oCikXeSqYQr0hBMARwg	Giulia Pompili - Breaking Italy Podcast	

Ho infine creato l'oggetto vuoto “**loop_com**” e con un loop recuperato i commenti per ogni video identificato nella lista “**E**”, per poi esportarli in formato xlsx:

```
# CREARE OGGETTO VUOTO
loop_com <- NULL

# LOOP
for (i in E$video_id) {
  dat <- get_all_comments(i)
  loop_com <- rbind(loop_com, dat)
  rm(dat)
  Sys.sleep(5)
}
```

Analizzare i testi

Individuazione delle multiwords

Ho creato l'oggetto "**testi**" riducendo in minuscolo il contenuto della colonna textOriginal di "**loop_commenti**", dopodiché ho tokenizzato i testi con l'oggetto "**toks**" e calcolato word_type e word_tokens inserendo gli indici 17 e 18 delle colonne nel data frame:

```
# Riduzione tutto minuscolo
testi<-tolower(loop_com$textOriginal)

# Tokenizzazione dei testi
toks<-tokens(testi)

# Calcoliamo Word_type & Word_token
loop_commenti<-cbind(loop_com, ntype(toks), ntoken(toks))%>%
  mutate(richness=ntype(toks)/ntoken(toks))
colnames(loop_commenti)[17] ="word_type"
colnames(loop_commenti)[18] ="word_token"
```

Ho allora creato le "**multiwords2**" (bi-grammi) e "**multiwords3**" (tri-grammi), rimuovendo le stopwords, e scelto quelle che mi servivano. Dopodiché ho unito i due oggetti in uno unico nominato "**multiwords**" che ho quindi esportato in formato xlsx:

```
multiwords2<-toks %>%
  tokens_remove(stopwords("it")) %>%
  tokens_remove(stopwords("en")) %>%
  tokens_select(pattern = "^[a-z]", valuetype = "regex", case_insensitive
    = FALSE, padding = TRUE) %>%
  textstat_collocations(min_count = 5, size=2)

multiwords3<-toks %>%
  tokens_remove(stopwords("it")) %>%
  tokens_remove(stopwords("en")) %>%
  tokens_select(pattern = "^[a-z]",
    valuetype = "regex", case_insensitive = FALSE, padding
    = TRUE) %>%
  textstat_collocations(min_count = 3, size=3)

multiwords2<-multiwords2[c(1,3,4,5,6,7,8,15,19,20,27,28,36,45,78,117,122,127,
  153,163,164),]
multiwords3<-multiwords3[c(3,7,9,11,14,20,21,24,30,37,40),]

multiwords<-rbind(multiwords2,multiwords3)
write.xlsx(multiwords, "multiwords.xlsx") e
multiwords<-as.character(multiwords2$collocation)
comp_toks<-tokens_compound(toks, pattern = phrase(multiwords))
```

collocation	count	count_nested	length	lambda	z
cecilia sala	59	0	2	7,20356017	28,8889133
giulia pompili	42	0	2	7,13408304	25,9780365
francesco costa	42	0	2	7,39597517	25,24824
molto interessante	48	0	2	4,33879355	24,2471686
super interessante	39	0	2	6,08280233	24,0875976
bellissima puntata	46	0	2	5,4966594	22,9458785
breaking italy	74	0	2	10,8695746	20,944347
grazie shy	24	0	2	3,32532503	14,7710939
tempi morti	7	0	2	8,87060263	13,9414648
corea sud	7	0	2	8,20715587	13,9163393
bellissima intervista	10	0	2	4,60632741	13,1654491
citazione tintoria	6	0	2	8,29368667	13,1102005
difficile seguire	6	0	2	6,02835045	12,7221078
luca sofri	6	0	2	9,47176133	11,7563859
repressione xinjiang	5	0	2	10,9143167	10,2482155
floris gigante	5	0	2	4,70096917	8,71831192

collocation	count	count_nested	length	lambda	z
bella intervista	5	0	2	3,78711	8,330087
grazie giulia	7	0	2	3,173945	8,204543
hong kong	6	0	2	14,12595	6,930929
nulla cosmico	5	0	2	9,113527	6,147713
stati anti-imperialisti	5	0	2	8,96709	6,051883
migliore puntata podcast	3	0	3	2,409004	1,466315
nessun campo lavoro	5	0	3	0,944286	0,365556
migliore fino ora	3	0	3	0,610347	0,287378
puntata molto interessante	9	0	3	0,126154	0,185456
miglior puntata night	3	0	3	0,070081	0,039863
senza filo logico	3	0	3	-0,63441	-0,27941
lavoro repressione xinjiang	5	0	3	-0,86161	-0,32233
campo lavoro repressione	5	0	3	-1,1762	-0,43655
podcast breaking italy	4	0	3	-2,39367	-1,12875
frasi lasciate metà	4	0	3	-3,64591	-1,53595
breaking italy night	9	0	3	-3,45799	-1,64578

Analisi

Ho creato l'oggetto "**vet**" per svolgere le operazioni successive di rimozioni delle stopwords, dei numeri, dei segni di punteggiatura, dei link, dei caratteri speciali, delle interruzioni di riga, degli spazi bianchi e della formattazione dal nuovo oggetto "**dataset**":

```
vet <- VCorpus(VectorSource(comp_toks))
```

Mostwords

Ho creato una matrice Termini-documenti "**dat.TDM**" e l'ho trasformata in una matrice normale "**dat.tm**". Ho quindi calcolato le somme delle frequenze "**dat.tsort**" e ordinato le parole dalla più alla meno frequente "**dat.tsort.dtm**", per poi esportarle in formato xlsx:

```
dat.TDM <- TermDocumentMatrix(dataset)
dat.tm <- as.matrix(dat.TDM)

dat.tsort <- sort(rowSums(dat.tm), decreasing = TRUE) |
dat.tsort.dtm <- data.frame(parola = names(dat.tsort), freq=dat.tsort)
write.xlsx(dat.tsort.dtm, "most.xlsx")
```

Contesto delle parole (1)

Ho verificato il contesto in cui sono inserite le parole "intervista", "giornalismo", "giornalista" e "chiacchierata" creando l'oggetto "**parole**" ed esportandolo in formato xlsx:


Ho poi creato un nuovo dataframe "**tb_most_word**" contenente le 15 parole più frequenti.

A questo punto, grazie al pacchetto **ggplot**, ho generato l'immagine del grafico con la frequenza delle parole più utilizzate.

```
parole <- kwic(tokens(testi), pattern = c("intervista", "giornalismo",
                                         "giornalista", "chiacchierata"),
              valuetype = "glob", window = 7)
write.xlsx(parole, "parole.xlsx")

tb_most_word <- dat.tsort.dtm[1:15,]

ggplot(tb_most_word, aes(reorder(parola, freq), y = freq)) +
  geom_bar(stat = "identity", color = "black", fill = "grey") +
  labs(title = "Le parole più utilizzate\n",
       x = "Parole",
       y = "Frequenza") +
  theme_classic() +
  coord_flip()
```



Udpipe completo

Ho lavorato con l'oggetto "**loop_video**" in modo da considerare i commenti di tutti e quattro i video. Ho ridotto a minuscolo i caratteri della colonna textOriginal dell'oggetto e generato un ID per ogni riga del dataset. Ho poi sostituito ogni multiword specifica con una versione senza spazi:

```
# ANNOTATION
loop_video$textOriginal <- tolower(loop_video$textOriginal)
loop_video$N_id <- 1:nrow(loop_video)

# Sostituzione multiword nel testo
for (i in seq_along(multiwords)) {
  replacement <- replacements[i]
  loop_video$textOriginal <- gsub(multiwords[i], replacement,
                                  loop_video$textOriginal)
}
```

Ho scaricato e caricato un modello di annotazione linguistica per l'italiano usando "**udpipe**", che ho usato nella colonna textOriginal, convertendo i risultati in un dataframe:

```
# Scarica e carica il modello di annotazione per l'italiano
ud_model <- udpipe_download_model(language = "italian")
ud_model <- udpipe_load_model(ud_model$file_model)


# Annotazione del testo
x <- udpipe_annotate(ud_model, x = loop_video$textOriginal, doc_id =
                      loop_video$N_id)
x <- as.data.frame(x)
```

Analisi delle occorrenze

Statistiche di frequenza

Ho ottenuto le statistiche di frequenza di occorrenza relative al sistema Universal Parts of Speech (UPOS) con l'oggetto **"stats"**:


```
# Frequenza delle parti del discorso
stats <- txt_freq(x$upos)
stats$key <- factor(stats$key, levels = rev(stats$key))
barchart(key ~ freq, data = stats, col = "cadetblue",
         main = "UPOS (Universal Parts of Speech)\n frequency of occurrence",
         xlab = "Freq")
```



Sostantivi

Con l'oggetto **"sostantivi"** ho creato un subset del dataframe x filtrando solo i sostantivi ed poi elencato i 20 con maggiori occorrenze in un grafico a barre:


```
# SOSTANTIVI
sostantivi <- subset(x, upos %in% c("NOUN"))
sostantivi <- txt_freq(sostantivi$token)
sostantivi$key <- factor(sostantivi$key, levels = rev(sostantivi$key))
barchart(key ~ freq, data = head(sostantivi, 20), col = "cadetblue",
  main = "Most occurring nouns", xlab = "Freq")
```



Aggettivi

Similmente ho fatto per gli “**aggettivi**”:

```
# AGGETTIVI
aggettivi <- subset(x, upos %in% c("ADJ"))
aggettivi <- txt_freq(aggettivi$token)
aggettivi$key <- factor(aggettivi$key, levels = rev(aggettivi$key))
barchart(key ~ freq, data = head(aggettivi, 20), col = "cadetblue",
  main = "Most occurring adjectives", xlab = "Freq")
```

Co-occorrenze di nomi e aggettivi nella stessa frase

Ho calcolato le co-occorrenze di sostantivi e aggettivi nella stessa frase creando la variabile **“cooc”**, che è poi stata convertita nel data frame **“cooc_data”**. Con la funzione `gsub()` ho poi sostituito alcuni termini indesiderati:

```
# 1. Sostantivi/aggettivi usati nella stessa frase
cooc <- cooccurrence(x = subset(x, upos %in% c("NOUN", "ADJ")),
                    term = "lemma",
                    group = c("doc_id", "paragraph_id", "sentence_id"))


cooc_dat <- data.frame(cooc)

# Sostituzione dei termini indesiderati nel dataframe delle co-occorrenze
cooc$term1 <- gsub("salo", "sala", cooc$term1)
cooc$term1 <- gsub("pompile", "pompili", cooc$term1)
cooc$term1 <- gsub("bello", "bella", cooc$term1)
cooc$term1 <- gsub("unico", "unica", cooc$term1)

cooc$term2 <- gsub("salo", "sala", cooc$term2)
cooc$term2 <- gsub("pompile", "pompili", cooc$term2)
cooc$term2 <- gsub("bello", "bella", cooc$term2)
cooc$term2 <- gsub("unico", "unica", cooc$term2)
```

Ho selezionato i 50 principali risultati di co-occorrenza dal data frame, creato un grafico con la funzione **igraph** e visualizzato con **ggraph**:

```
# Visualizzazione della rete di co-occorrenze
wordnetwork <- head(cooc_dat, 50)
wordnetwork <- graph_from_data_frame(wordnetwork)
ggraph(wordnetwork, layout = "fr") +
  geom_edge_link(aes(width = cooc, edge_alpha = cooc), edge_colour = "pink") +
  geom_node_text(aes(label = name), col = "darkgreen", size = 4) +
  theme_graph(base_family = "sans") + # Usa una famiglia di caratteri standard
  theme(legend.position = "none") +
  labs(title = "Cooccurrences within sentence", subtitle = "Nouns & Adjective")
```



Co-occorrenze di nomi e aggettivi che si susseguono

Ho calcola le co-occorrenze di sostantivi e aggettivi che si susseguono utilizzando un modello di skipgram uguale a “1”.

Ho selezionato le 25 co-occorrenze più frequenti e rappresentate con un grafico (come al punto precedente):

```
cooc <- cooccurrence(x$token, relevant = x$upos %in% c("NOUN", "ADJ"),
                    skipgram = 1)

head(cooc)

library(igraph)
library(gggraph)
library(ggplot2)

wordnetwork <- head(cooc, 25)
wordnetwork <- graph_from_data_frame(wordnetwork)
gggraph(wordnetwork, layout = "fr") +
  geom_edge_link(aes(width = cooc, edge_alpha = cooc)) +
  geom_node_text(aes(label = name), col = "darkgreen", size = 4) +
  theme_graph(base_family = "Arial Narrow") +
  labs(title = "Words following one another", subtitle = "Nouns & Adjective")

cooc_dat <- data.frame(cooc)
```

Words following one another

Nouns & Adjective



Correlazioni

Ho quindi utilizzato una matrice termini-documenti per calcolare le **correlazioni tra i termini che appaiono spesso insieme**, pur essendo poco frequenti.

```
x$id <- unique_identifier(x, fields = c("sentence_id", "doc_id"))
dtm <- subset(x, upos %in% c("NOUN", "ADJ"))
dtm <- document_term_frequencies(dtm, document = "id", term = "lemma")
dtm <- document_term_matrix(dtm)
dtm <- dtm_remove_lowfreq(dtm, minfreq = 5)
termcorrelations <- dtm_cor(dtm)
y <- as_cooccurrence(termcorrelations)
y <- subset(y, term1 < term2 & abs(cooc) > 0.2)
y <- y[order(abs(y$cooc), decreasing = TRUE), ]
head(y)
```

term1	term2	cooc
327310	moschee	uguario 1.0000000
331734	arabo	usanza 0.9485870
98532	costanzo	maurizio 0.9127783
112146	aumento	moschee 0.8449828
326881	aumento	uguario 0.8449828
359773	repressione	xinjiang 0.7213071

Contesto delle parole (2)

Ho infine verificato in che contesto fossero inserite le parole “giornalista”, “giornalismo”, “informazione”, “intervista”, “chiacchierata” e “Italia”, visualizzando per ognuna 7 parole a sinistra e 7 a destra e creando un data frame, poi esportato in xlsx:

```
giornalista<-kwic(tokens(testi),pattern = "giornalista",
                  valuetype="glob", window = 7)
giornalista_df <- as.data.frame(giornalista)
write.xlsx(giornalista_df, file = "giornalista_kwic.xlsx")
```

	docname	from	to	pre	keyword	post	pattern
1	text5	5	5	e questa è una	giornalista	?	giornalista
2	text15	5	5	una caratteristica del bravo	giornalista	è la loquacità e l'utilizzo di termini	giornalista
3	text21	19	19	io l'ho vista perché adoro sala come	giornalista	. questa puntata mi ha un pó	giornalista
4	text23	4	4	lei è una	giornalista	incredibilmente brava . la chiaccherata però risulta	giornalista
5	text31	5	5	ma come fa una	giornalista	a dire ogni tre per due "	giornalista
6	text49	6	6	un po ' timida sta	giornalista		giornalista
7	text54	130	130	stati più interessanti come la carriera da	giornalista	. le interviste nei paesi in guerra	giornalista
8	text92	20	20	loro commenti . cecilia sala è una	giornalista	che stimo moltissimo e mi aspettavo di	giornalista
9	text105	16	16	pubblico o improvvisare , se sei un	giornalista		giornalista
10	text116	64	64	puntata siamo forse al quarto / quinto	giornalista	? alla lunga i temi sono sempre	giornalista